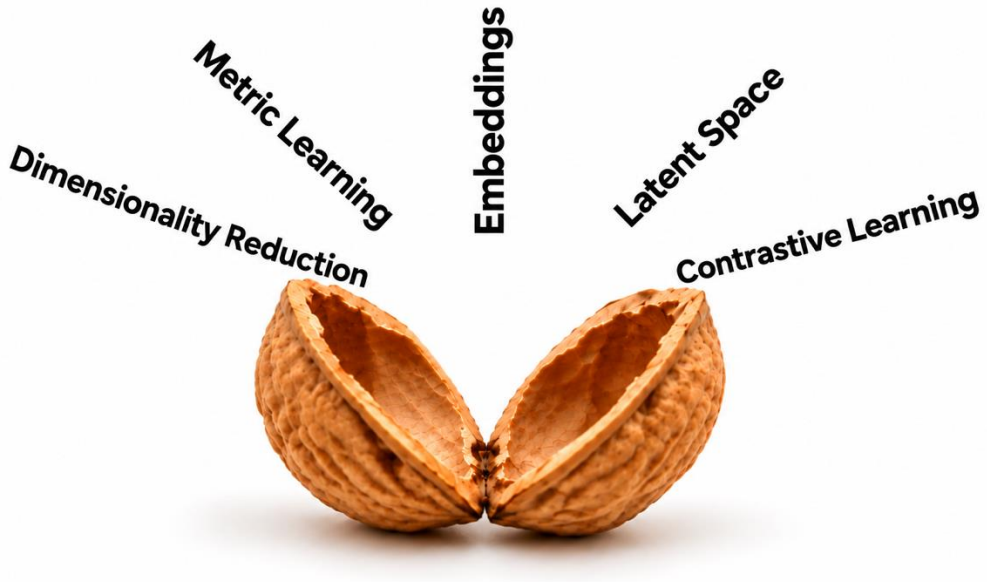
Representation Learning in a



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Chi sono



Simone Bonfrate

AI and Data Engineer @ BIP xTech

- 🎓 Politecnico di Bari - AI & Data Science
- 🎮 Switch2 player
- 🎲 Cyberpunk GDR Master

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Con la collaborazione di

Pierfrancesco Favino



DevFest

Allora è vero che alla fine tutti i ruoli li fa Favino....

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Cos’è rappresentazione?

"L’attività e l’operazione di rappresentare con figure, segni e simboli sensibili, o con processi vari, anche non materiali, oggetti o aspetti della realtà, fatti e valori astratti, e quanto viene così rappresentato."

Treccani

"L’operazione di semplificazione di un elemento desiderato al fine di raggiungere un obiettivo"

Io, Inventato durante uno spinello

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Favino vede un albero e lo disegna





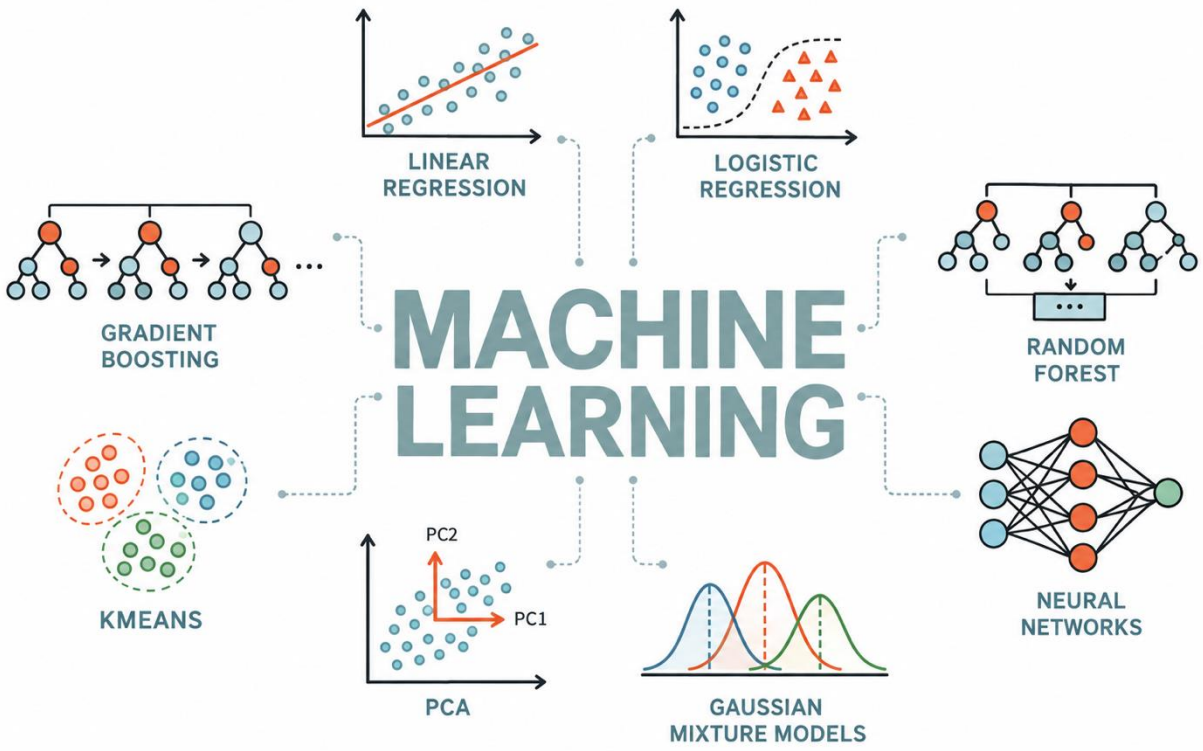


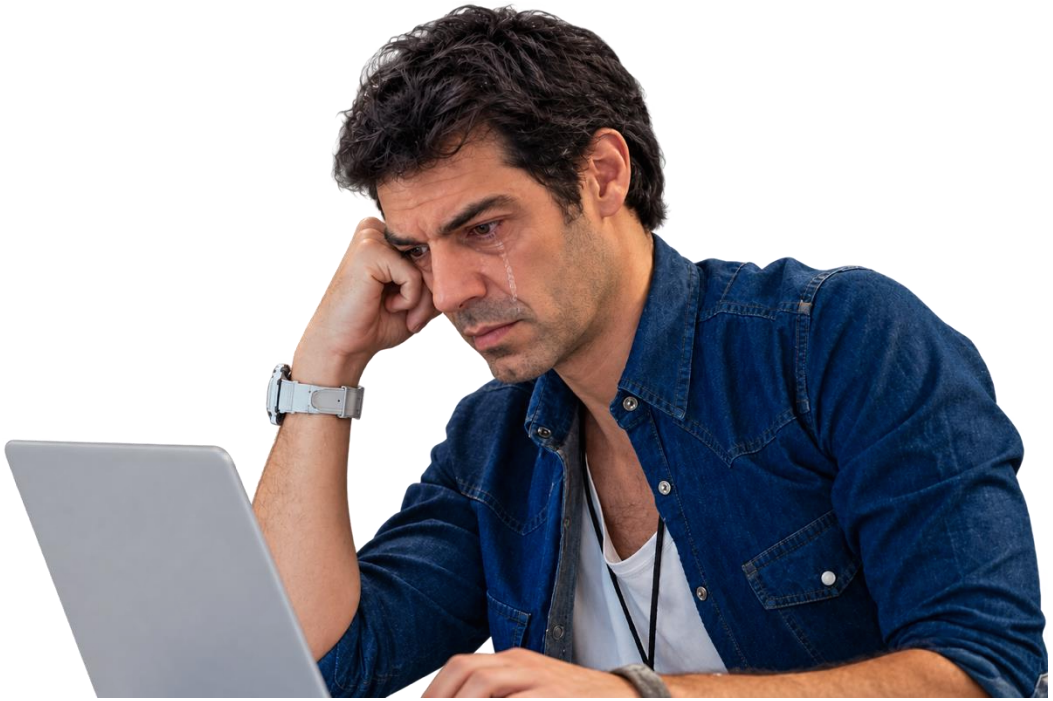
Possiamo considerare il disegno una rappresentazione?

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Dopo molto tempo… Favino finisce ad ingegneria informatica (ML I)

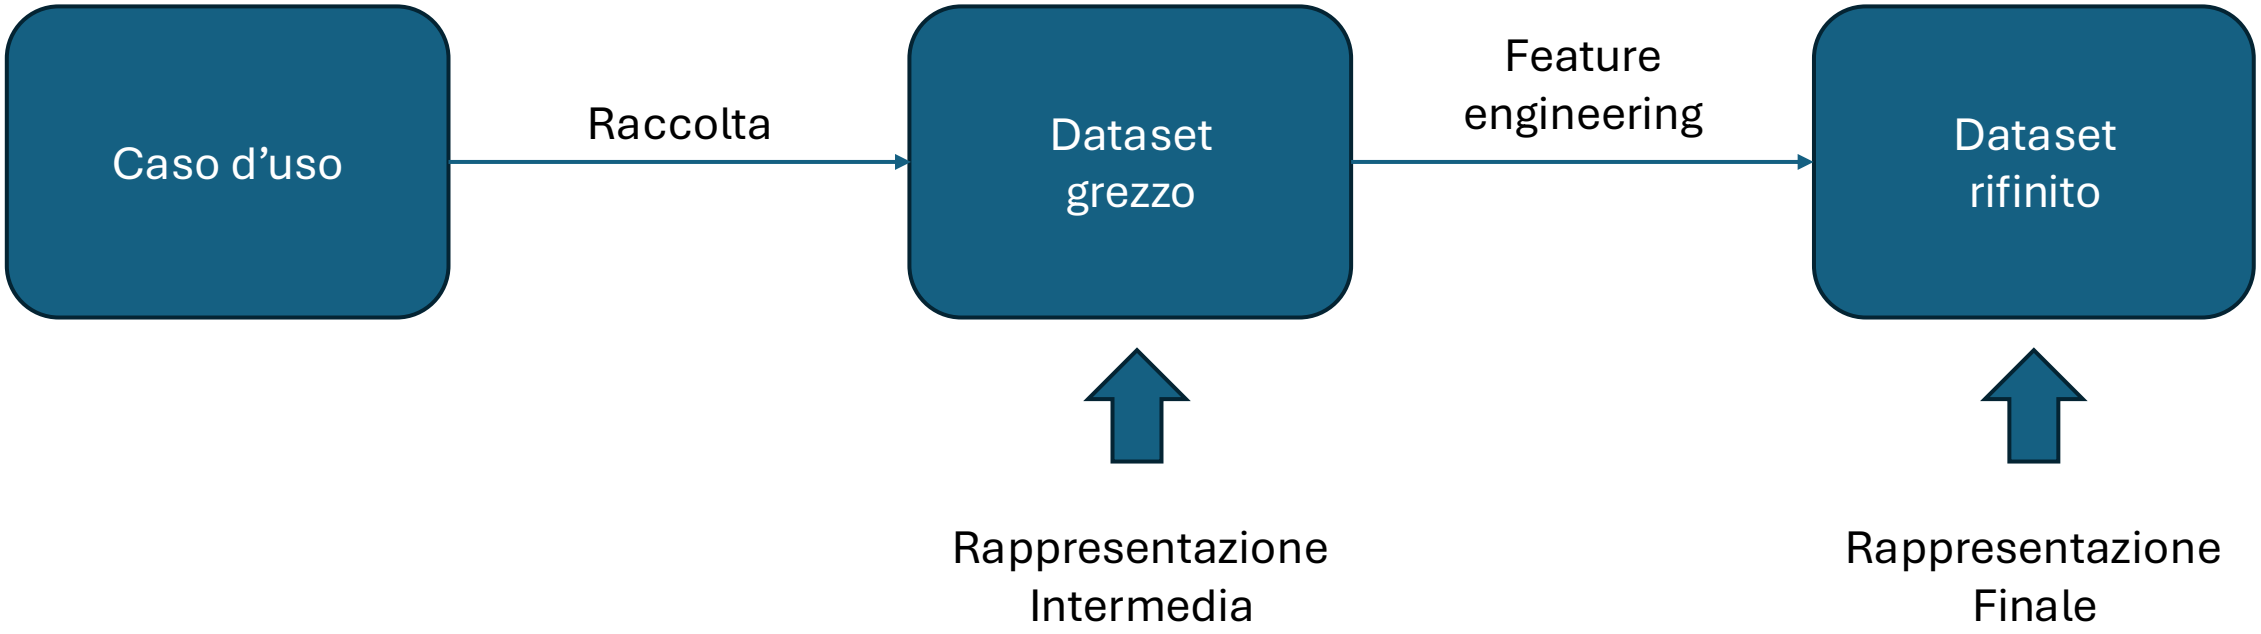




DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

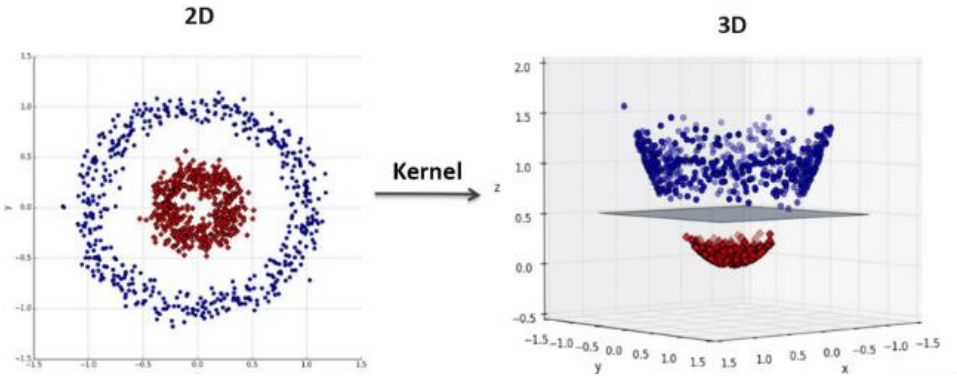
Machine Learning – Il data scientist prepara la rappresentazione adatta al modello

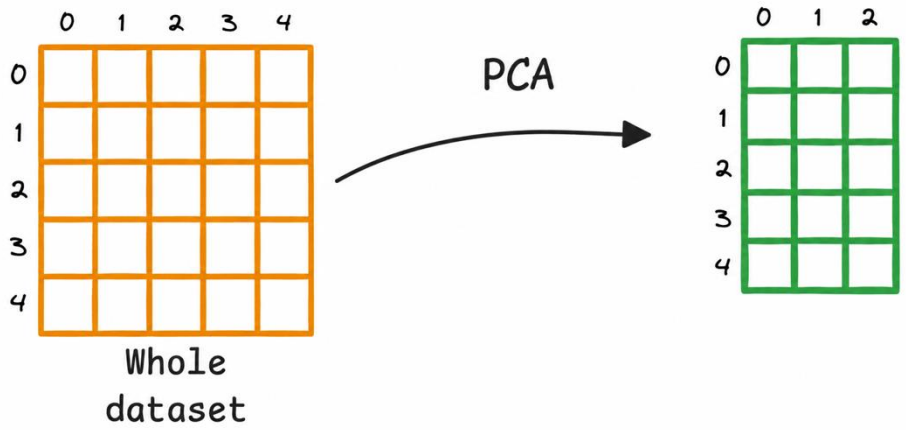


DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Machine Learning – Sfruttare lo spazio delle feature a proprio vantaggio





Kernel

Applicare una trasformazione per separare i dati appartenenti a classi diverse

PCA

Comprimere i dati in uno spazio vettoriale di minore dimensione

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Favino va in Erasmus…

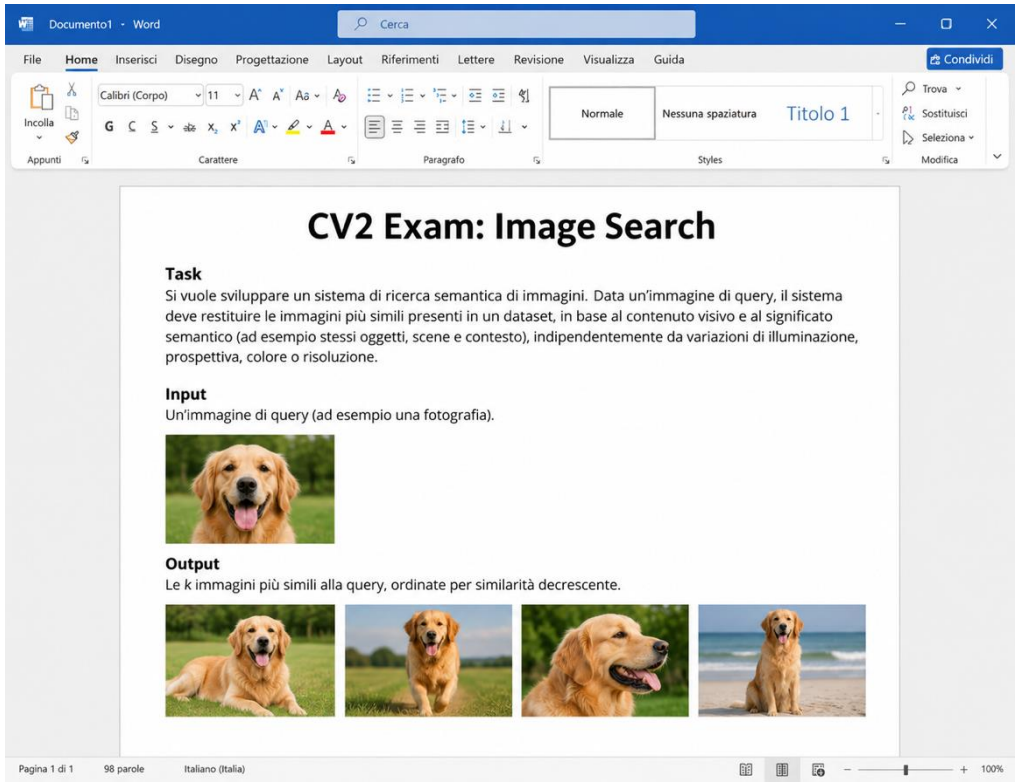


DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Favino va in Erasmus… ma si accorge che deve studiare anche lì





DevFest

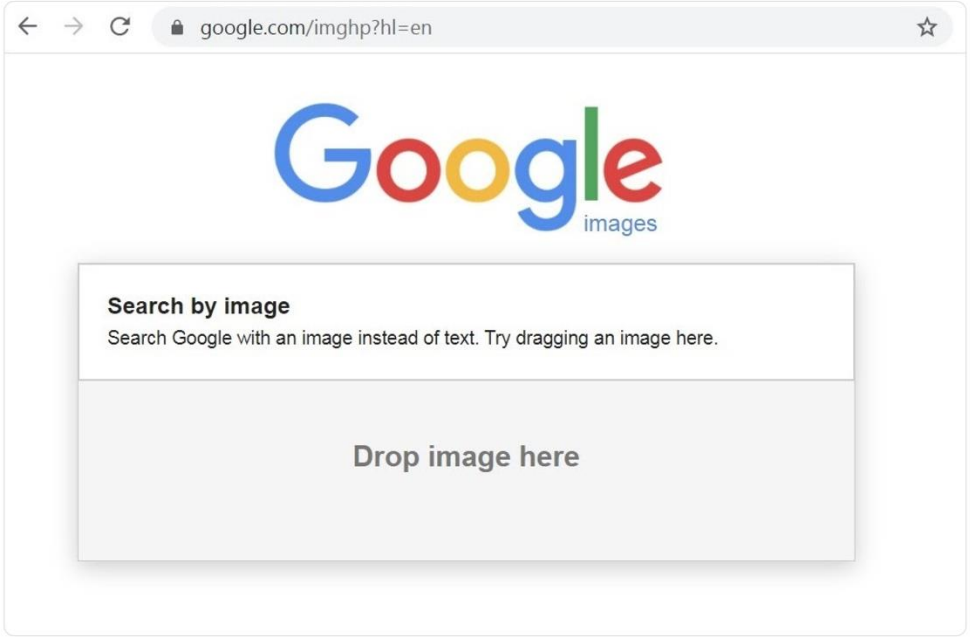
I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

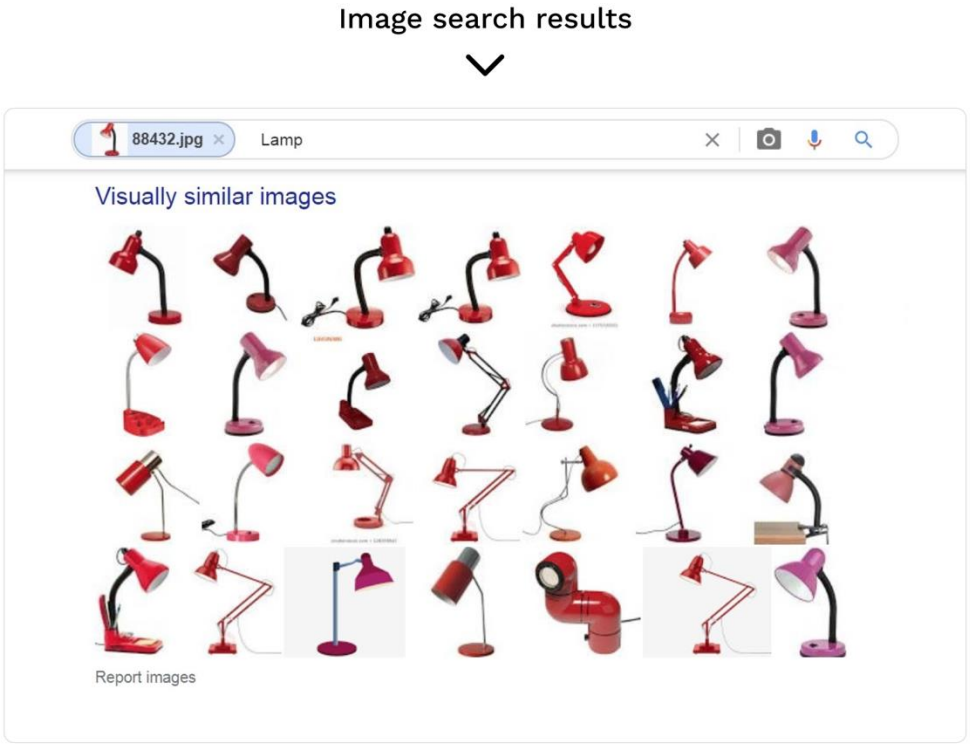
Ricerca immagini per similarità

Dato una foto, l'obiettivo è restiruire i riferimenti più simili.

Un approccio classico; che sfrutta descrittori e brute force matching delle feature visive estratte, non è in grado di restituire immagini semanticamente simili.

Come possiamo risolvere?

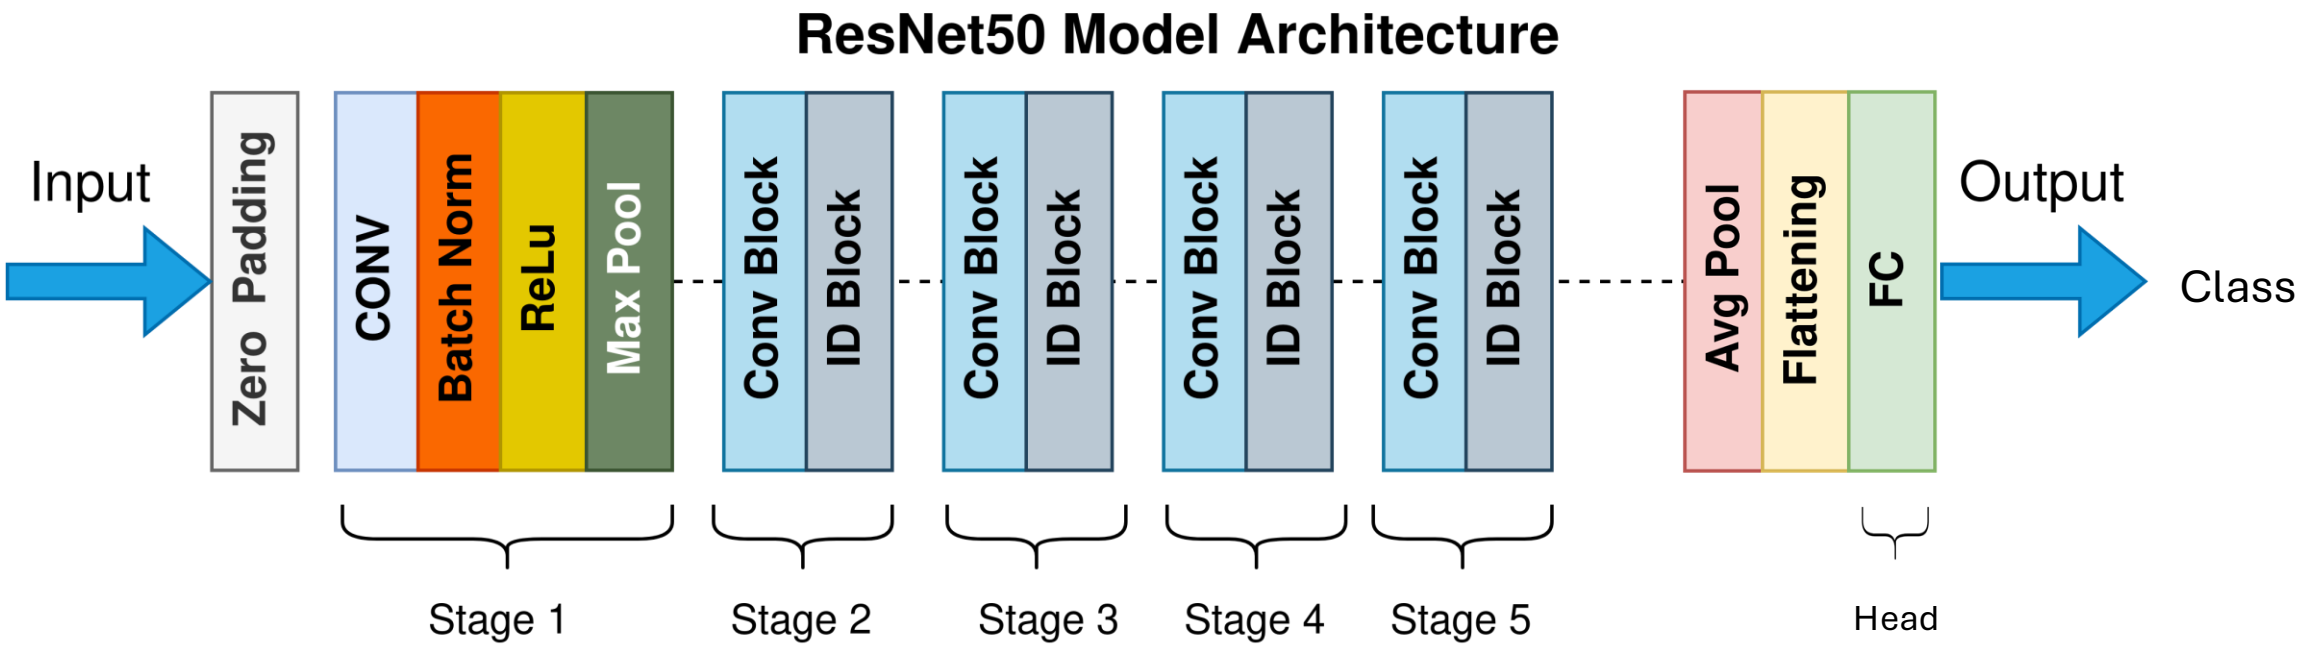




DevFest

I conter

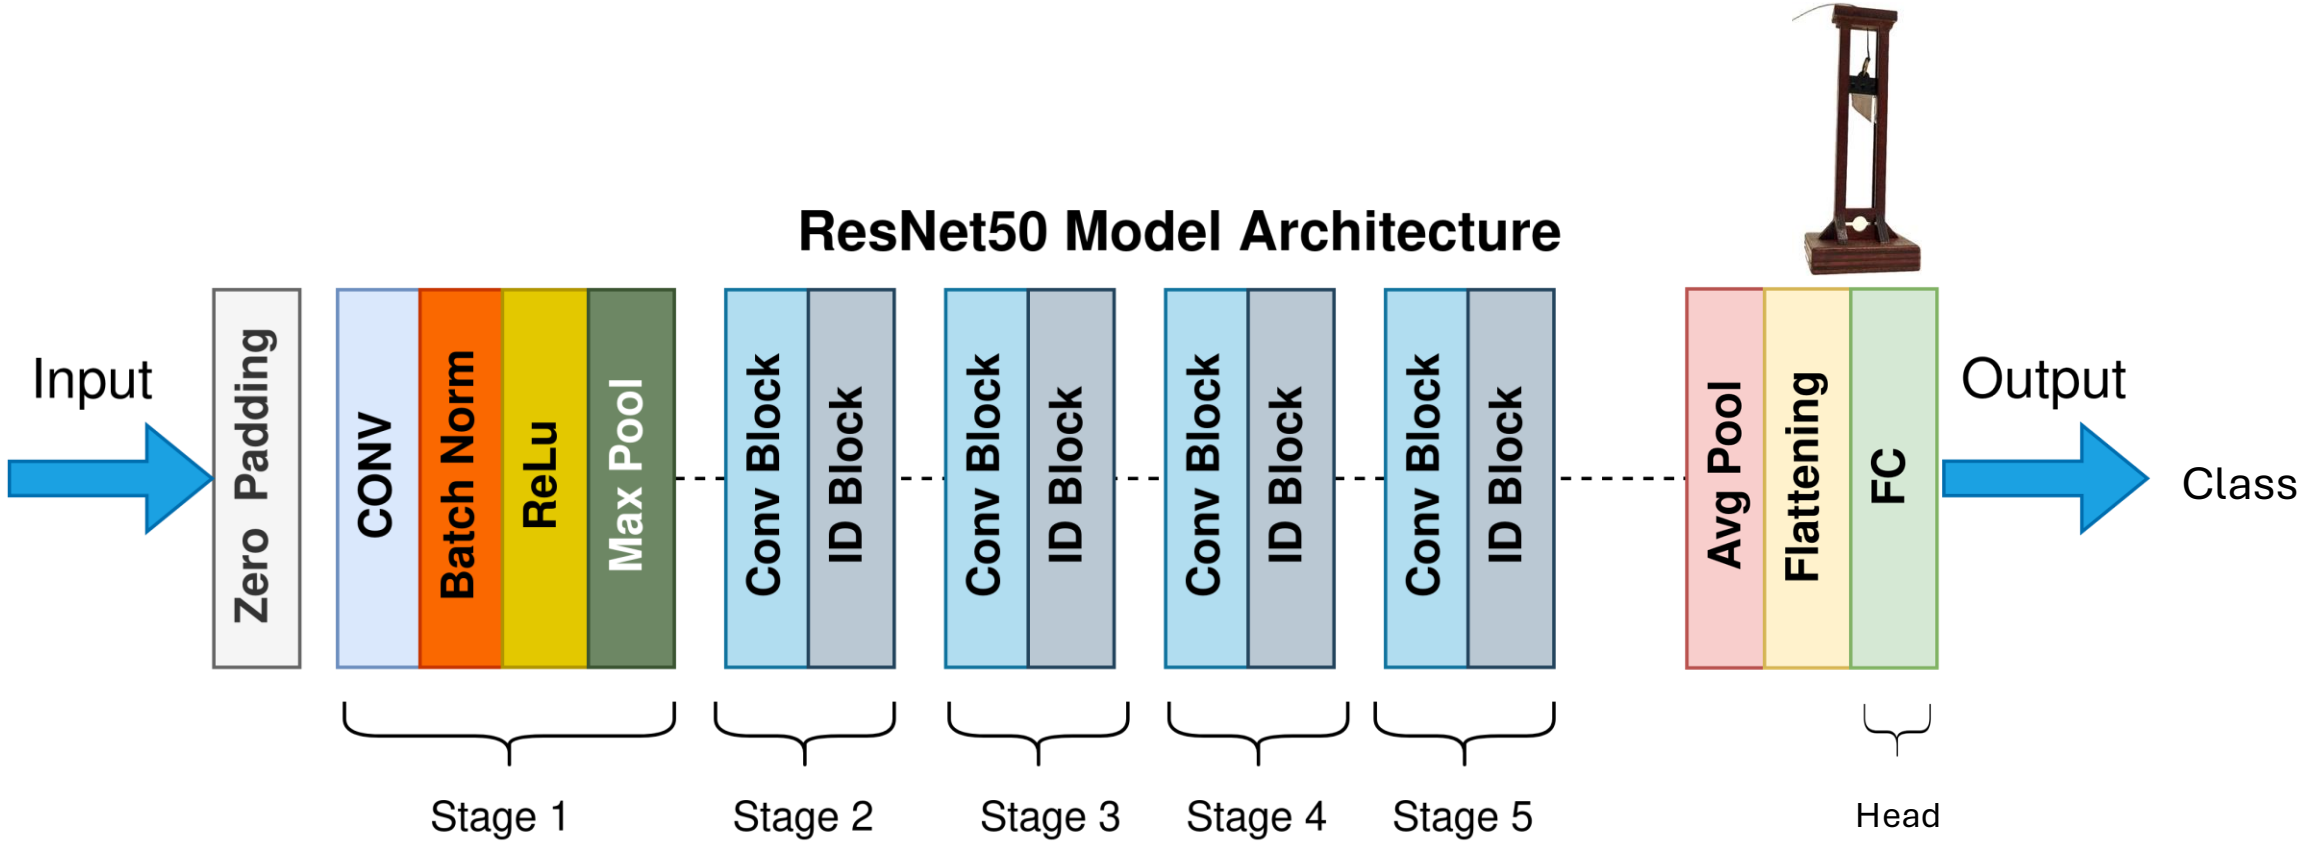
Ricerca immagini per similarità - Modello



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

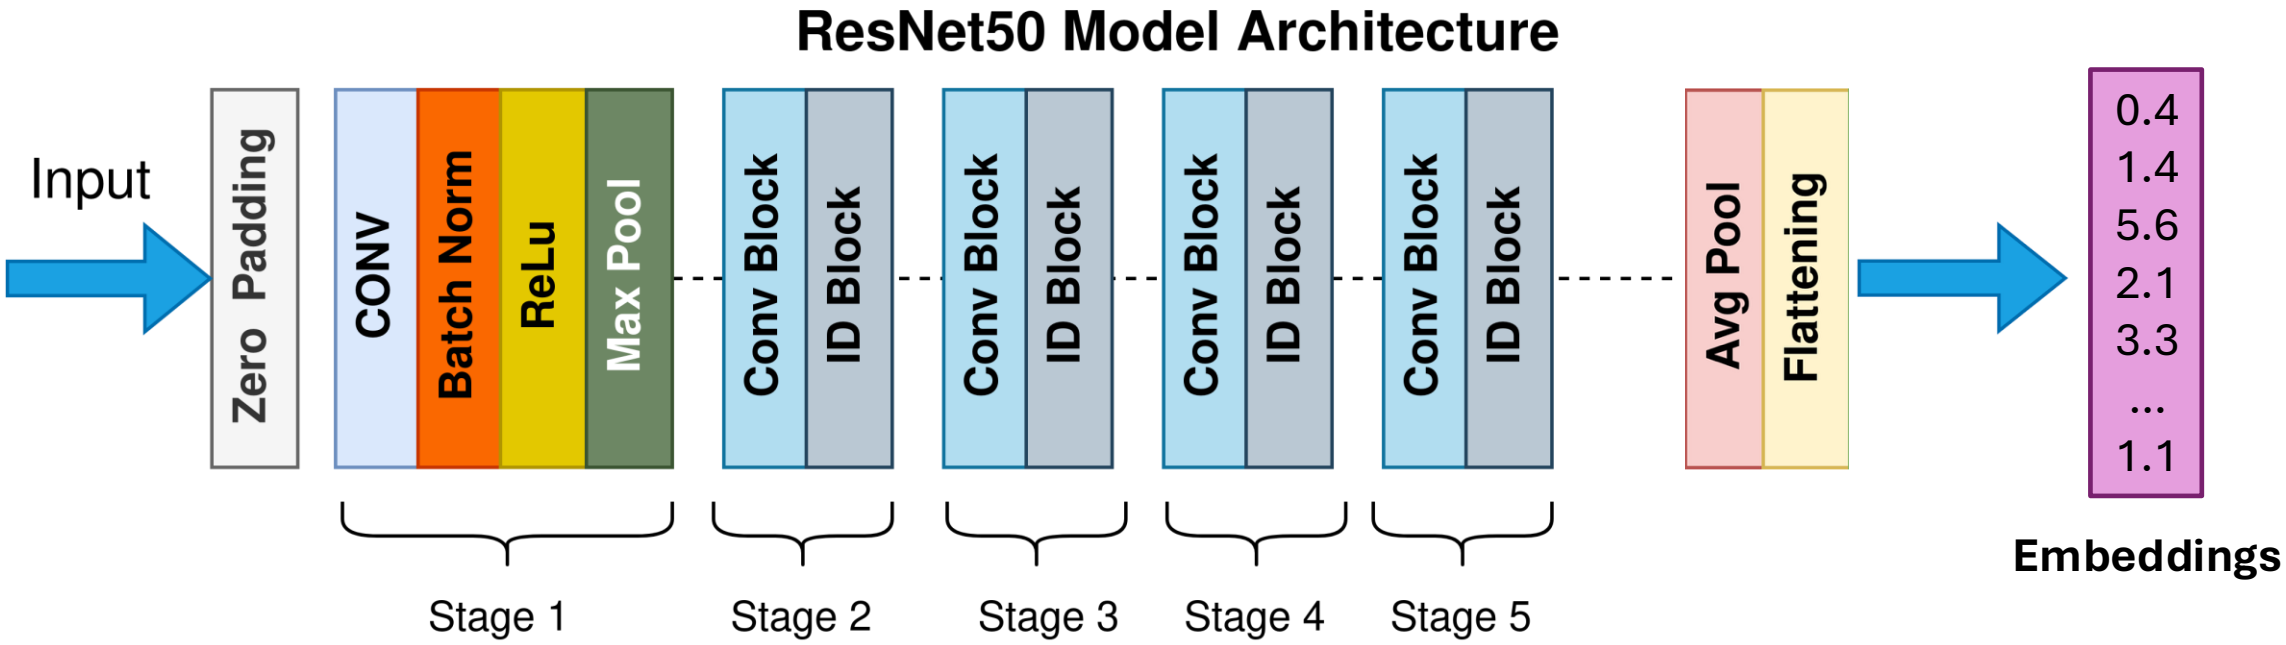
Ricerca immagini per similarità - Modello



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Ricerca immagini per similarità - Modello



DevFest

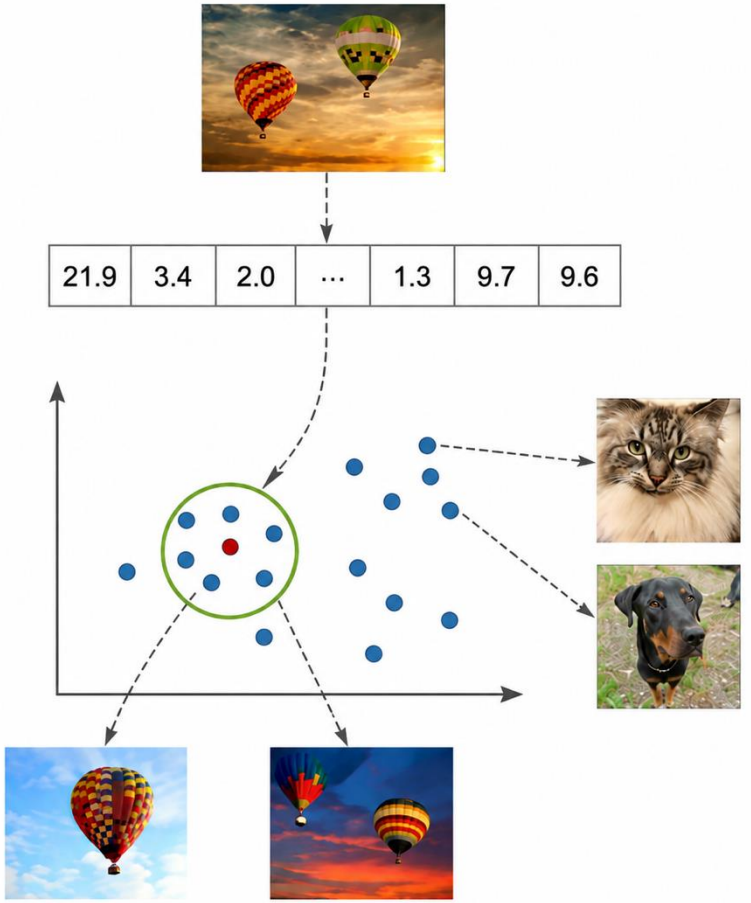
I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Embedding

Rappresentazione vettoriale numerica del dato originale. Il modello eseguire una proiezione delle informazioni in uno spazio vettoriale di dimensioni compatte, definito **Spazio Latente**.

Questa astrazione permette di estrarre la semanticità dei dati:
- Immagini (CNN, ViT)
- Testo (BERT-based models)
- Audio (CNN, Transformer)

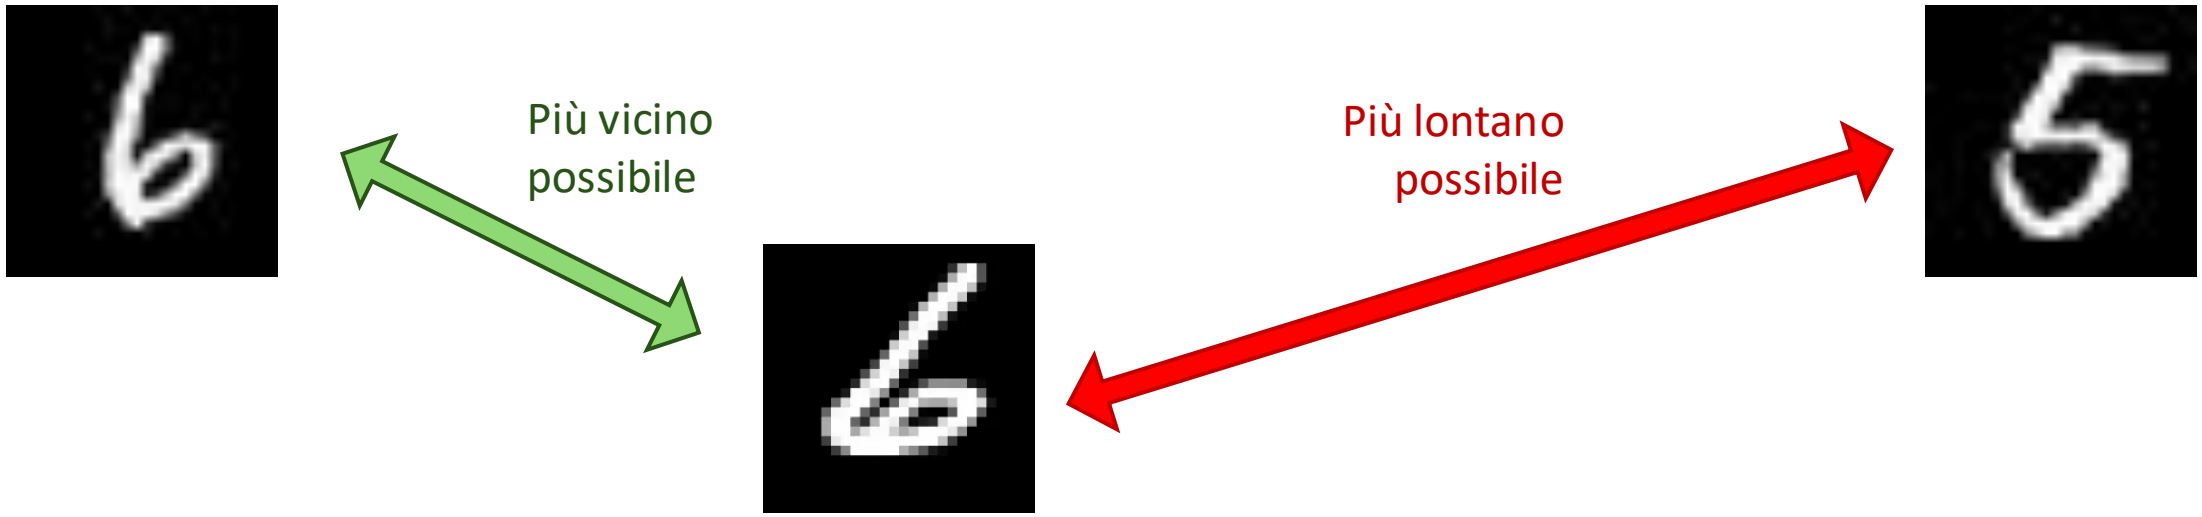
Gli embedding possono essere confrontati tramite:
- Distanza Euclidea
- Similarità del coseno
- Dot product



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Come imparare a generare embedding altamente semantici?



Tramite il **(Distance) metric learning**, il modello impara a generare rappresentazioni in cui la distanza tra elementi simili è bassa e la distanza tra oggetti lontani è alta.

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

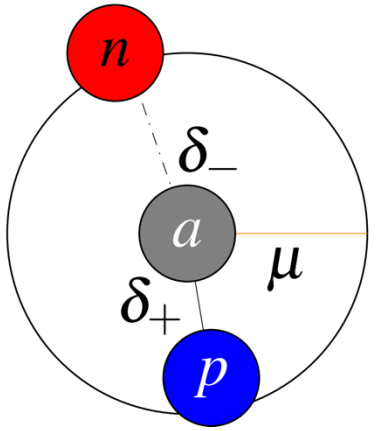
Metric Learning - TripletLoss

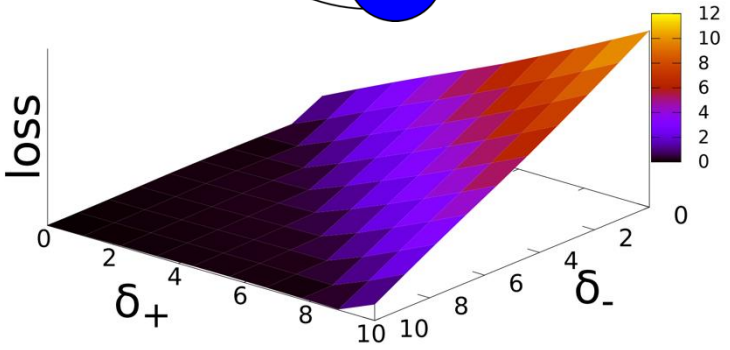
Batch → A - Ancora
P – Esempio positivo
N – Esempio negativo → Embedding → Distanze:
1. A-P
2. A-N → TripletLoss

TripletMarginLoss:

- $L(a, p, n) = \max\{ d(a_i, p_i) - d(a_i, n_i) + \text{margin}, 0\}$
- $d(x_i, y_i) = \|\mathbf{x}_i - \mathbf{y}_i\|_p$

Premia la vicinanza al positivo (δ_+) e la distanza dal negativo (δ_-), p rappresenta il grado della norma.

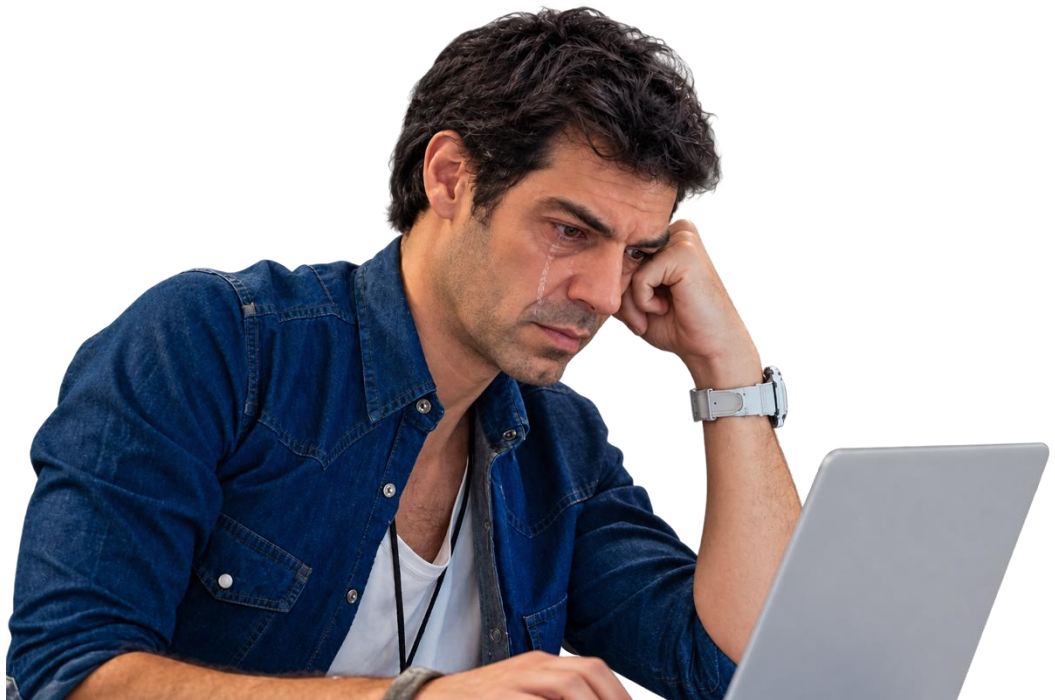




DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Favino sta preparando la tesi sulla ricerca multimodale



Search by text

cups in the google logo colors

Search results

60 results retrieved from a total of 5,748,850 items



#0

Vintage Tupperware Kids Cup Tumblers Red, Green, Blue



#1

Harkins Theater Movie Collector Cups 6pc 2023 2019 Sold out plastic



#2

4 STARBUCKS Tazo Mugs Asymmetrical Tea Cup Bone China Tumbler. Maroon and blue



#3

Vintage Tupperware 4 Small Tumbler Kids Cups Stackable 3.75" Tall



#4

Lot of 6 Tupperware Sippy Bell Tumblers YELLOW BLUE GREEN RED NO LIDS.



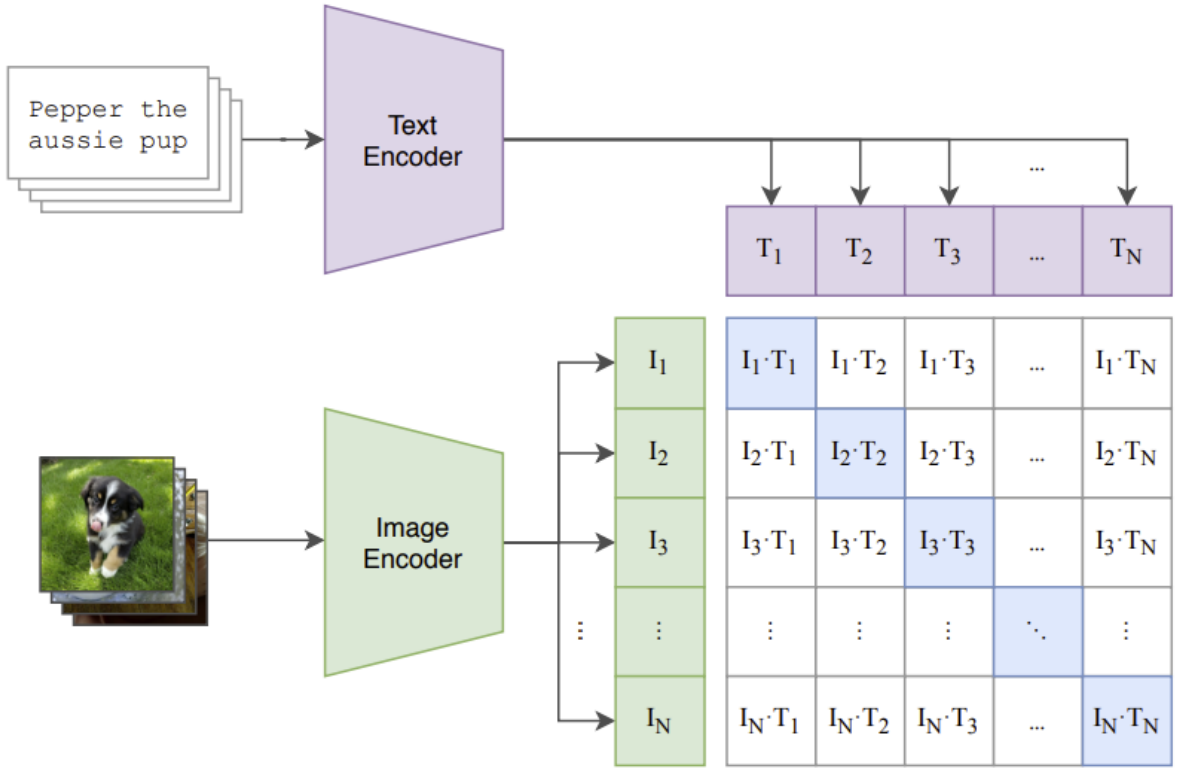
#5

Vintage lot of 4 Tupperware Jazzy Celebrations Tumblers jewel tones

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Visual Language Model – Spazio latente allineato tra modali

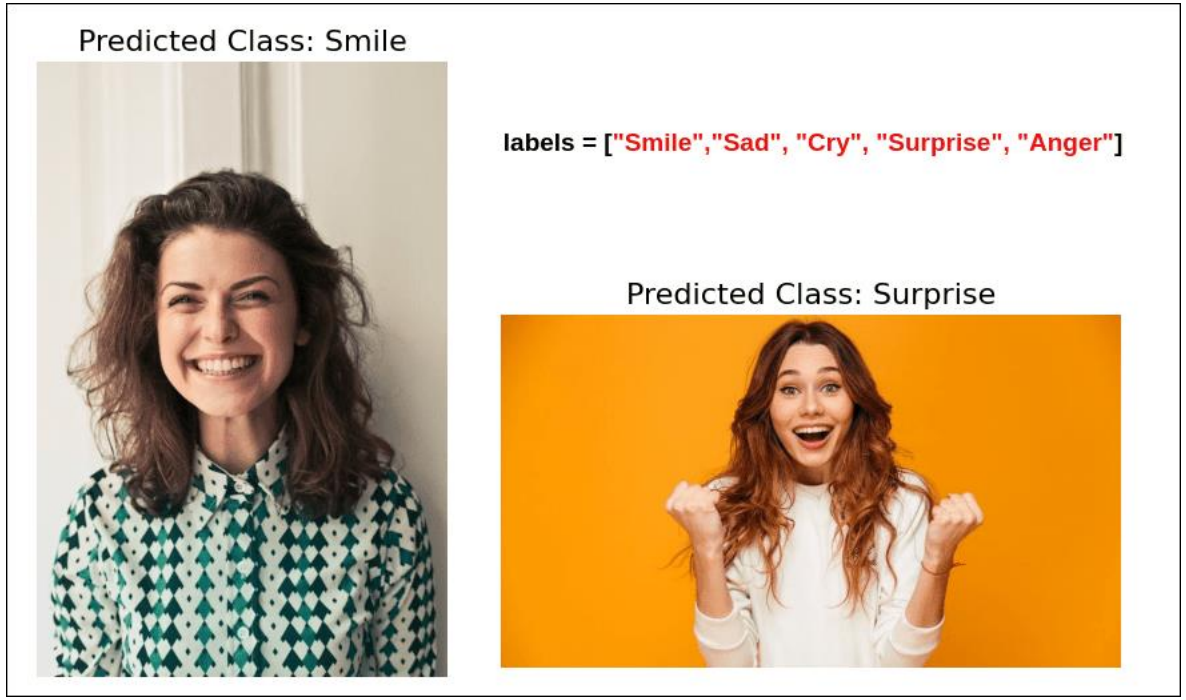
Due modelli, che condividono la stessa dimensionalità dello spazio latente, vengono allineati affinché le caption testuali possano recuperare gli item pertinenti appartenenti ad un'altra modale.



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

VLM – Casi d’uso



Zero shot classification (label-free)



Visual Question Answering
Q: What is the dog holding with its paws?
A: Frisbee.



Visual Reasoning
Q: Is the dog in the air **AND** is the frisbee in the air?
A: Yes

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

CLIP – Esempio con Hugging Face

```python
from PIL import Image
import requests

from transformers import CLIPProcessor, CLIPModel

model = CLIPModel.from_pretrained("openai/clip-vit-base-patch32")
processor = CLIPProcessor.from_pretrained("openai/clip-vit-base-patch32")

# Zero-shot classification

url = "http://images.cocodataset.org/val2017/000000039769.jpg"
image = Image.open(requests.get(url, stream=True).raw)

inputs = processor(text=["a photo of a cat", "a photo of a dog"], images=image, return_tensors="pt", padding=True)

outputs = model(**inputs)
logits_per_image = outputs.logits_per_image # this is the image-text similarity score
probs = logits_per_image.softmax(dim=1) # we can take the softmax to get the label probabilities

# Multimodal search

imgs = [...]
imgs_prep = processor(images=imgs, return_tensors="pt")
imgs_embedding = model.get_text_features(**inputs).float()

query = "..."
query_prep =  processor(text=[query], return_tensors="pt", padding=True)
query_emb = model.get_text_features(**inputs).float()

scores = F.cosine_similarity(image_features, query_features,  dim=-1)
values, indices = scores.topk(min(3, len(images)))
```

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

BLIP – Esempio con Hugging Face

```python
from transformers import AutoProcessor, Blip2ForConditionalGeneration
import torch

processor = AutoProcessor.from_pretrained("Salesforce/blip2-opt-2.7b")
model = Blip2ForConditionalGeneration.from_pretrained("Salesforce/blip2-opt-2.7b", torch_dtype=torch.float16)

# Image captioning

inputs = processor(image, return_tensors="pt").to(device, torch.float16)

generated_ids = model.generate(**inputs, max_new_tokens=20)
generated_text = processor.batch_decode(generated_ids, skip_special_tokens=True)[0].strip()
print(generated_text) # "two cartoon monsters sitting around a campfire"

# Visual Question Answering

prompt = "Question: What is a dinosaur holding? Answer:"

inputs = processor(image, text=prompt, return_tensors="pt").to(device, torch.float16)

generated_ids = model.generate(**inputs, max_new_tokens=10)
generated_text = processor.batch_decode(generated_ids, skip_special_tokens=True)[0].strip()
print(generated_text) "A torch"
```


I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

VLM – Modelli



CLIP
by OpenAI



SigLIP
by Google



BLIP
by Salesforce

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

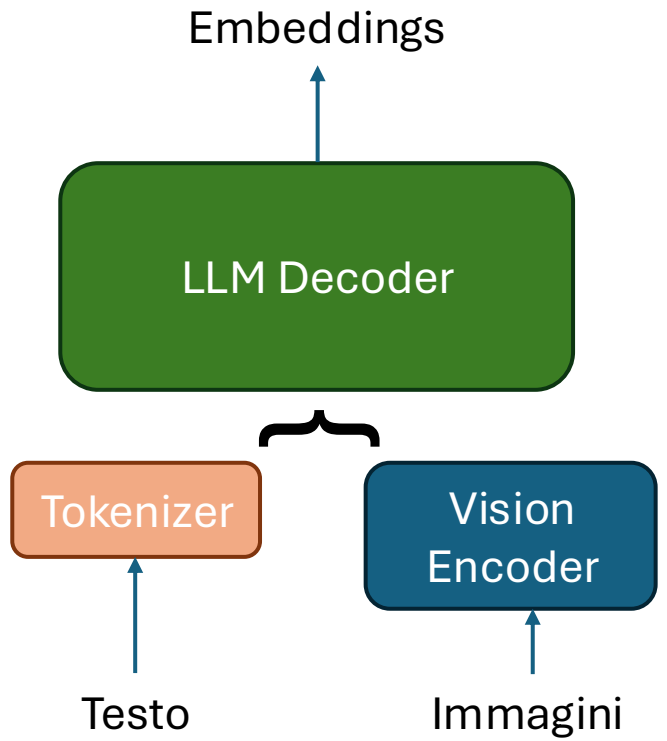
LVLM – Unico spazio latente per più modali

I Large Vision Language Models sono dei LLM che possono ricevere in input token testuali e visivi (generati dal vision encoder)

Permette il modello di accedere alla conoscenza visiva e testuale contemporaneamente ed a processare per riuscire ad estrarre concetti e leggi del mondo rappresentato dall'intero prompt.

Il risultato finale è un unico vettore di embedding semantico che continene la comprensione del prompt (che coincide con l'ultimo stato nascosto prima di ottenere i logits del primo token).

NB: essendo un estensione del LLM, la struttura del prompt condiziona la qualità degli embedding



I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

GME – Generalist Multimodal Embeddings

Modelli VLM/LVLM allenati verticalmente per task di retrieval. Consentono di generare embedding per query e documenti per effettuare la ricerca.

UEmbed
by (Qwen) Alibaba

EmbeddingGemma2
by Google

WeMMEmbedding
by WeChat (Tencent)

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

LVLM – Come scalare con la ricerca semantica?

Ottenuti gli embedding, è necessario implementare un motore di ricerca che permette di accedere alle informazioni pertinenti con basse latenze e che possa scalare in base al carico.

Il vector database rappresenta il componente che permette di eseguire la ricerca semantica sui i documenti indicizzati.

Qdrant

Pinecone

Postgres + PG Vector



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Alla fine… Favino si laurea e si apre la partita iva

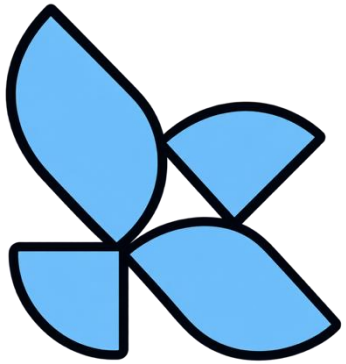


DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Il task che deve implementare il nostro ing. Favino

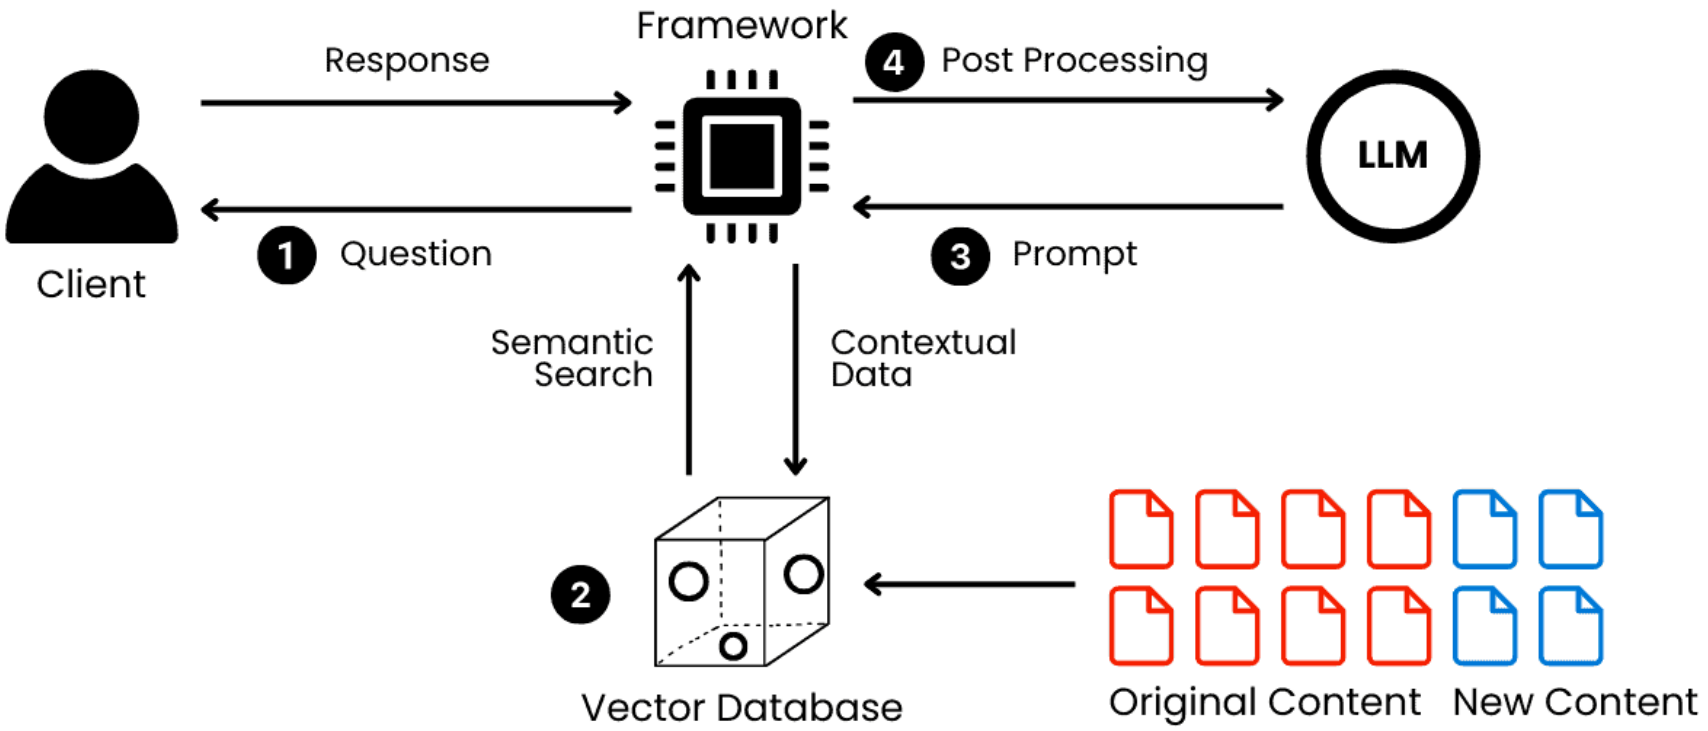
- LLM open-weights
- Basse latenze
- Risposta basata su documenti locali
- Esecuzione su edge device (DGX spark)
- Nessun accesso a internet



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

RAG – Retrival Augmented Generation

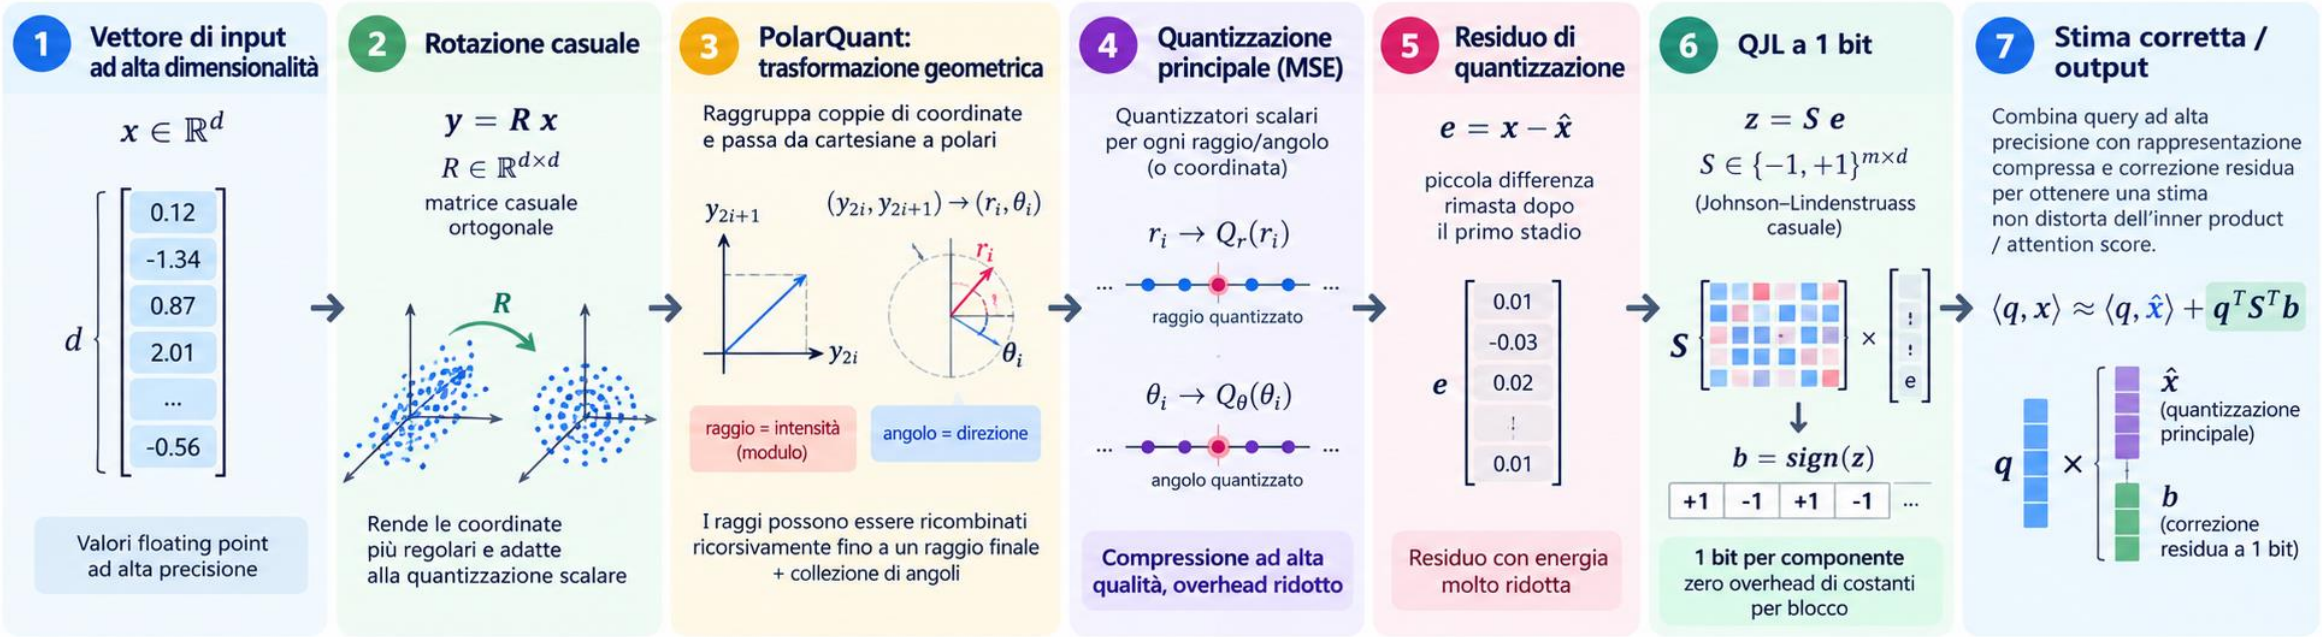


DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

DB vettoriale troppo grande? Quantiziamolo

TurboQuant - Google, 2026



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

TurboVec – Turboquant for embeddings

E’ possibile applicare TurboQuant nel task di retrieval? Si, con la libreria turbovec

```python
from sentence_transformers import SentenceTransformer
from turbovec import TurboQuantIndex

documents = get_documents() # your logic

model = SentenceTransformer("google/embeddinggemma-2")
embeddings = model.encode(documents)

index = TurboQuantIndex(dim=1536, bit_width=4)
index.add(embeddings)


query = "..."
query_emb = query_emb = model.encode(
    query,
    prompt_name="SearchQuery")

scores, indices = index.search(query_emb, k=5)
print(indices)        # [[    0 86544  3385 84492 24967]]   int64 slot positions
print(scores.shape)   # (1, 5)
```

DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

TurboVec – langchain retriever adapter

E’ possibile integrarlo anche all’interno di langchain come vector store e retriever

```python
from langchain_google_genai import GoogleGenerativeAIEmbeddings
from turbovec.langchain import TurboQuantVectorStore

embeddings = GoogleGenerativeAIEmbeddings(model="gemini-embedding-2")

store = TurboQuantVectorStore.from_texts(
    texts=["Document 1...", "Document 2...", "Document 3..."],
    embedding=embeddings,
    bit_width=4,
)

retriever = store.as_retriever(search_kwargs={"k": 5})
matched_docs = retriever.get_relevant_documents(query = query)
```


I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Conclusioni

Anche se l’evoluzione dei sistemi agentici ha preso un’altra direzione, le tecniche di representation learning rimangono valide per:

- Ricerca semantica multimodale
- Sistemi di raccomandazione multimodali
- System 1 Model (CLM-v0.1)



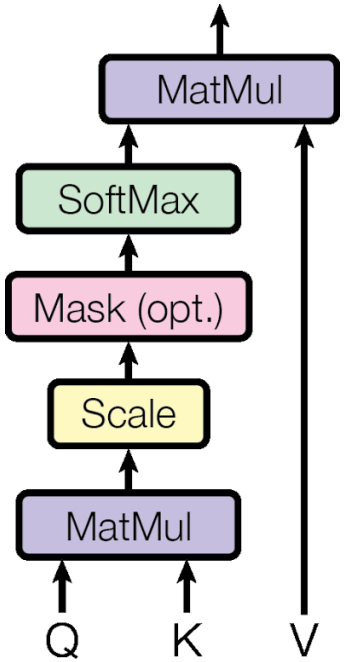
I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Domande?



I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro

Grazie per l’



DevFest

I contenuti espressi nel talk non sono frutto di esperienze svolte presso il datore di lavoro